

FlowHub – Arc42

Architekturdokumentation

CAS AI-Assisted Software Engineering (AISE) · W4B-C-AS001 · ZH-Sa-1 · FS26 **Student:** Andreas Imboden **Version:** 2.0 (as built) · **Stand:** Juni 2026 · **Template:** arc42 v8 (adaptiert)

Hinweis zur Version. Version 1.0 (Februar 2026) dokumentierte die *geplante* Konzept-Architektur zu Projektbeginn. Diese Version 2.0 beschreibt die **tatsächlich gebaute** Lösung am Abgabestand und kennzeichnet bewusst, wo das Konzept (Zielbild) über das Umgesetzte hinausgeht. Die Quell-Artefakte (Projektbeschreibung, ADRs 0001–0009, Design-Dokumente) liegen im Repository: <https://github.com/freaxnx01/FlowHub-CAS-AISE>.

1. Einführung und Ziele

FlowHub ist ein **KI-gestützter persönlicher Eingangskorb**. Er nimmt Informationsschnipsel aus dem Alltag entgegen (ein Film-Tipp, ein Fachartikel, ein Beleg-Foto, eine Notiz), **erkennt und klassifiziert** sie automatisch und **leitet sie an den passenden Ziel-Dienst** weiter — ohne dass der Benutzer im Moment der Erfassung entscheiden muss, wohin die Information gehört.

Das adressierte Kernbedürfnis ist „**Capture without friction**“: Statt der heutigen fünf Schritte (Idee → App-Wahl → App öffnen → Kategorisieren → Ablegen) reduziert FlowHub die Erfassung auf einen einzigen Schritt. Die Klassifikation übernimmt ein **Skill-basiertes Routing-System**: ein LLM klassifiziert den Schnipsel, deterministisches Keyword-/URL-Muster-Matching dient als Fallback.

1.1 Aufgabenstellung

- **Funktional:** Captures über mehrere Kanäle entgegennehmen, automatisch klassifizieren, an den passenden externen Dienst routen und den Lebenszyklus jedes Captures (inkl. Fehlerfälle und Retry) nachvollziehbar machen.
- **Qualitativ:** saubere, begründete Architektur (Modular Monolith, hexagonal), dokumentierte Architekturentscheidungen (ADRs) und eine reflektierte, KI-unterstützte Entwicklungsweise.

- **Rahmen:** Umsetzung inkrementell über die fünf CAS-Blöcke (Einführung, Frontend, Service, Persistence, Deployment).

KI-Nutzen je Kernfunktion (ein Satz pro Funktion):

- **Erfassung:** KI macht die Ein-Schritt-Erfassung möglich — der Nutzer muss im Moment des Capture nicht entscheiden, wohin die Information gehört.
- **Klassifikation:** ein LLM erkennt Typ und Ziel-Skill des Captures, mit deterministischem Keyword-Matching als Fallback.
- **Anreicherung:** das LLM ergänzt Titel und Tags, die der Nutzer sonst manuell setzen müsste.
- **Routing:** profitiert direkt von der KI-Klassifikation — der richtige Ziel-Dienst wird ohne Nutzer-Entscheid gewählt.
- **Semantische Suche:** Embeddings erlauben Suche nach Bedeutung statt nach exakten Stichwörtern.

1.2 Qualitätsziele

Die Qualitätsziele sind als SMART-Anforderungen in `docs/spec/nfa.md` spezifiziert (Volltext-Tabelle in Kapitel 10). Die fünf tragenden Ziele:

Priorität	Qualitätsziel	Konkretisierung
1	Performance	Capture-Listen-Abfrage (Limit ≤ 50) p95 < 100 ms (NfA-01); B-Tree-Indizes auf allen häufigen Filterspalten (NfA-02).
2	Betriebbarkeit	Migrations-first, idempotentes SQL als Init-Container, nie Auto-Migrate in <code>app.Run()</code> (NfA-03).
3	Zuverlässigkeit	Npgsql-Connection-Pooling + transiente Retry-Policy (NfA-05); Retry + Fault-Observer in der Async-Pipeline.
4	Beobachtbarkeit	Prometheus- <code>/metrics</code> -Endpoint, <code>dotnet_*</code> - und <code>http_*</code> -Serien (NfA-O1).
5	Datenschutz (Ziel)	Verarbeitung möglichst auf eigener Infrastruktur (NfA-P1), KI-Transparenz/Provenienz (NfA-P2) — noch nicht umgesetzt , siehe Kapitel 11.

1.3 Stakeholder

Stakeholder	Rolle	Erwartung an die Architektur
Homelab-Operator (Primärnutzer)	Betreibt FlowHub selbst (Proxmox/Docker), nutzt bereits Vikunja, Wallabag, paperless-ngx	Reibungslose Erfassung; self-hostbar; nachvollziehbarer Verbleib jeder Information
„Digital Hoarders“ (Sekundär)	Sammeln viel, ohne abzulegen	Niedrigschwellige Erfassung
CAS-/FFHS-Dozenten (Bewertung)	Beurteilen die Projektarbeit	Verteilte Web-App mit KI, saubere Architektur, ADRs, KI-Einsatz-Reflexion

FlowHub ist bewusst ein **Single-Operator-System**, keine Multi-User-Plattform (siehe Abgrenzung, Kapitel 11 / Projektbeschreibung §10).

2. Randbedingungen

2.1 Technische Randbedingungen

Bereich	Festlegung
Plattform	.NET 10 / C# / ASP.NET Core (LTS)
Frontend	Blazor Web App (Interactive Server) + MudBlazor als einzige Komponenten-Bibliothek
API	ASP.NET Core Minimal APIs, versioniert unter <code>/api/v1</code> , Fehler als RFC 9457 ProblemDetails
Persistenz	EF Core 10 + PostgreSQL 17 (Image <code>pgvector/pgvector:pg17</code>); Code-First-Migrations
Messaging	MassTransit (In-Memory in Dev/Test, RabbitMQ in Prod via <code>Bus__Transport</code>)

Bereich	Festlegung
KI-Abstraktion	Microsoft.Extensions.AI (<code>IChatClient</code>); Provider via <code>Ai__Provider</code> wechselbar
Build/Betrieb	Multi-Stage-Dockerfile (<code>sdk:10.0-alpine</code> → <code>aspnet:10.0-alpine</code> , non-root), Docker Compose
Konventionen	Warnings-as-Errors, Nullable Reference Types, SemVer, Conventional Commits, 12-Factor

2.2 Organisatorische Randbedingungen

- **CAS-Struktur:** fünf FFHS-Blöcke (1 Konzept, 2 Frontend, 3 Service/REST, 4 Persistence, 5 Deployment), Abgabe Juli 2026. Jeder Block schliesst mit einer dokumentierten Nachbereitung ab, die gegen die Moodle-Bewertungskriterien selbst geprüft wird.
- **Dokumentation:** arc42 als Architektur-Vorlage; Architekturentscheidungen als ADRs (Kapitel 9).
- **Stack-Wahl:** Die freie Technologie-Wahl wurde in der PVA bestätigt. Wo der Kurs einen Quarkus-/Jakarta-EE-Stack als Beispiel nennt, setzt FlowHub funktionale .NET-Äquivalente ein (EF Core ↔ Hibernate/Panache, MassTransit ↔ Queue-basiertes Messaging, MEAI ↔ Spring-AI). Das Programmierkriterium der Rubrik ist seit dem Update Juni 2026 framework-neutral.

3. Kontextabgrenzung


3.1 Fachlicher Kontext

FlowHub sitzt zwischen **Eingangs-Kanälen** und **Ziel-Diensten**:

- **Eingangs-Kanäle (gebaut):** Web Quick-Capture (Eingabefeld in der Blazor-AppBar) und REST-API `POST /api/v1/captures` . Ein **Telegram-Bot** ist konzipiert, aber **nicht umgesetzt**.
- **Ziel-Dienste:** Wallabag (Read-Later), Vikunja (Tasks/Kanban) — beide als `ISkillIntegration` -Adapter **gebaut**; paperless-ngx (DMS) in der Live-Demo; Obsidian/GitLab als Wissens-Ablage **geplant**. Fällt keine Zuordnung, bleibt der Capture in der FlowHub-Inbox (PostgreSQL).

Skill → Ziel-Dienst (Konzept-Mapping): Artikel → Wallabag; Homelab/Buch/Film → Vikunja; Dokument → paperless-ngx; Wissen/Zitat → Obsidian/GitLab; generisch → Inbox. **Wired am Abgabestand:** Wallabag und Vikunja.

3.2 Technischer Kontext



Ist-Stand-Hinweis. Das Kontextdiagramm zeigt das Gesamtbild inkl. geplanter Bausteine. Am Abgabestand umgesetzt sind die sechs Projekte `FlowHub.{Web,Core,Api,AI,Persistence,Skills}` mit Wallabag- und Vikunja-Adapttern; **Telegram-Kanal, lokales Ollama, Authentik/OIDC und der Obsidian-Pfad sind geplant** (KI läuft heute über Cloud-Provider, Auth über Dev-Bypass). paperless-ngx ist nur in der Live-Demo angebunden.

Beziehung	Mechanismus
Operator → Web-UI	HTTP + SignalR (langlebiger Blazor-Interactive-Server-Circuit)
Web / API → Core	In-Process-DI (kein HTTP für UI-Daten, ADR 0001)
Core → KI-Provider	REST (Cloud: OpenRouter/Mistral heute; lokales Ollama als Ziel, ADR 0007)


Beziehung	Mechanismus
Skills → externe Dienste	HTTP REST (Wallabag, Vikunja)
Web → Authentik (OIDC)	geplant — heute Dev-Bypass (<code>DevAuthHandler</code>)

4. Lösungsstrategie

Problem / Treiber	Lösungsansatz	Begründung / ADR
Klare Modulgrenzen ohne Microservice-Overhead	Modularer Monolith — ein deploybarer Prozess, Fähigkeiten als getrennte .NET-Projekte, modulübergreifende Aufrufe nur über Ports in <code>FlowHub.Core</code>	ADR 0001, ADR 0002
Testbarkeit, austauschbare Infrastruktur	Hexagonale Schichtung je Modul — Driving-Ports (<code>IClassifier</code> , <code>ICaptureService</code>) und Driven-Ports (<code>ISkillIntegration</code> , <code>Repositories</code>) im Core, Adapter in den Fähigkeits-Projekten	ADR 0002
Entkopplung Erfassung ↔ Verarbeitung, Resilienz	Asynchrone Pipeline über MassTransit (In-Memory in Dev, RabbitMQ in Prod); ausgehende Integrationen synchron innerhalb der Consumer	ADR 0002, ADR 0003
Austauschbarkeit des LLM-Providers	KI-Provider-Abstraktion (MEAI <code>IChatClient</code>); Anthropic + OpenRouter; <code>KeywordClassifier</code> als deterministischer Fallback-Boden	ADR 0004
KI-Suche ohne separate Vektor-DB	pgvector auf derselben PostgreSQL statt zusätzlicher Infrastruktur	ADR 0006

5. Bausteinsicht

5.1 Ebene 1 — Module (Ist-Architektur)



Modul	Verantwortung
FlowHub.Core	Domänen-Typen (Capture , Skill , Health) + Driving-/Driven-Ports (IClassifier , IEmbeddingService , ISkillIntegration , Repository-Interfaces). Keine Infrastruktur-Referenzen.
FlowHub.Web	Blazor Web App (Interactive Server, MudBlazor) + MassTransit-Consumer (/Pipeline/) + Host des Minimal-API. Komponiert FlowHub.Api in-process (kein separater Container).
FlowHub.Api	Minimal-API-Endpunkte (CaptureEndpoints , SearchEndpoints , AdminEndpoints) als In-Process-Library.
FlowHub.AI	AiClassifier + AiEmbeddingService über MEAI.
FlowHub.Persistence	EF Core + PostgreSQL + pgvector; sechs Ef*Repository - Implementierungen.
FlowHub.Skills	ISkillIntegration -Adapter für Wallabag und Vikunja.

Diese sechs Projekte bilden die vollständige `FlowHub.slnx`. Telegram-Kanal und generische Integrations-Schicht sind **geplant, nicht gescaffolded**.

5.2 Skill-System (Kernarchitektur)

- **IClassifier** (Driving-Port): `ClassifyAsync(content) → ClassificationResult (Tags, MatchedSkill, Title?)`. Zwei Adapter: **KeywordClassifier** (Regeln) und **AiClassifier** (MEAI; füllt zusätzlich Title).
- **ISkillIntegration** (Driven-Port): `Name + HandleAsync(Capture) → SkillResult`. Auflösung per exaktem `Name == MatchedSkill`.
- **SkillRoutingConsumer** ist der Dispatcher: kein Treffer → `MarkUnhandledAsync` (Capture bleibt in der Inbox).

5.3 Ebene 2 — MassTransit-Pipeline (5 Consumer)

Die Async-Pipeline ist die innere Zerlegung des Host-Prozesses. Jeder Consumer ist ein eigener Baustein mit klarer Verantwortung und eigener Retry-Policy:

Consumer	Reagiert auf	Verantwortung	Retry
<code>CaptureEnrichmentConsumer</code>	<code>CaptureCreated</code>	Klassifikation via <code>IClassifier</code> ; setzt <code>Classified</code> oder <code>Orphan</code>	<code>[100ms, 500ms]</code>
<code>SkillRoutingConsumer</code>	<code>CaptureClassified</code>	Auflösung <code>ISkillIntegration</code> per <code>Name</code> ; Write; setzt <code>Routed / Unhandled</code>	<code>[500ms, 2s, 5s]</code>
<code>CaptureEmbeddingConsumer</code>	<code>CaptureCreated</code>	Best-Effort-Embedding (pgvector); parallel zum Enrichment	<code>[500ms, 2s, 5s]</code>
<code>CaptureNotificationConsumer</code>	Lifecycle-Events	optionale ntfy.sh-Benachrichtigung	—
<code>LifecycleFaultObserver</code>	<code>Fault<...></code>	bildet Faults auf <code>Orphan / Unhandled</code> ab (kein Retry)	keine

Zwei Events tragen die Pipeline: `CaptureCreated` (nach dem Submit) und `CaptureClassified` (nach erfolgreicher Klassifikation). Enrichment und Embedding hängen beide am `CaptureCreated` und laufen damit parallel.

5.4 Ebene 2 — Skill-System (Ports & Adapter)


```
Capture submitted
→ IClassifier.ClassifyAsync(content) (Driving-Port, FlowHub.Core)
→ ClassificationResult { MatchedSkill, Tags, Title? }
→ CaptureClassified (MassTransit-Event)
→ SkillRoutingConsumer
→ ISkillIntegration where Name == MatchedSkill (Driven-Port, FlowHub.Core)
→ integration.HandleAsync(capture) → SkillResult
```

- **IClassifier** — zwei Adapter: **KeywordClassifier** (deterministische Regeln, immer `Title = null`) und **AiClassifier** (MEAI; füllt zusätzlich `Title`, fällt bei Provider-Fehlern auf **KeywordClassifier** zurück).
- **ISkillIntegration** — ein Adapter je Ziel-Dienst, jeder kapselt HTTP/Auth/Tagging selbst. Verdrahtet: **Wallabag**, **Vikunja**. Auflösung per exaktem `Name` - Match gegen `MatchedSkill`.
- **Einen Skill ergänzen** (Erweiterungspunkt): **ISkillIntegration** in `FlowHub.Skills/<Service>/` implementieren, in den DI-Extensions registrieren, dem Classifier den neuen `MatchedSkill` beibringen. Roadmap: paperless-ngx, Wekan, Obsidian/GitLab teilen denselben Vertrag.

5.5 Paketstruktur

Flaches Layout `source/FlowHub.<Capability>/` (ADR 0001). Keine Sibling-Projekt-Referenzen zwischen Fähigkeiten; jede Abhängigkeit läuft über einen Port in `FlowHub.Core`.


5.4 Datenmodell



Captures ist das Aggregat-Root. Das **Embedding** (pgvector-Spalte mit **HNSW**-Index — *Hierarchical Navigable Small World*, ein Approximate-Nearest-Neighbour-Index für schnelle Vektor-Ähnlichkeitssuche — mit Cosine-Distanz) kam in Block 5 hinzu; auf der öffentlichen Demo sind Embeddings deaktiviert (`/search` → 503), siehe ADR 0006 (inkl. Amendment).


6. Laufzeitsicht

6.1 Capture-Lebenszyklus



`Raw → Classified → Routed → Completed` ist der Happy Path; `Orphan` (kein Skill / Enrichment-Fault) und `Unhandled` (kein Adapter / Routing-Fault) sind die retry-baren Terminal-Zustände — beide kehren über den Retry-Endpunkt nach `Raw` zurück.


6.2 Hot-Path — Submit → Skill-Write



Wesentlich: Die HTTP-Antwort (201) erfolgt **vor** Klassifikation und Routing — der Submit-Pfad bleibt schnell, die teure Arbeit läuft asynchron. Enrichment und Embedding laufen parallel; das Embedding ist Best-Effort.

6.3 Enrichment — Happy Path (AI-Classifier erfolgreich)


Gilt, wenn `Ai_Provider` und der passende API-Key gesetzt sind. `AiClassifier` macht **einen** strukturierten Provider-Call, validiert das Schema und liefert `ClassificationResult(Tags, MatchedSkill, Title)`. Ein leerer `MatchedSkill` ist ein *gültiges* Ergebnis (→ `MarkOrphanAsync`), keine Exception.



6.4 Enrichment — Fallback (Provider-Fehler → KeywordClassifier)


Jede Exception aus `IChatClient` (Netzwerk, Timeout, JSON-Parse, Schema-Verletzung) wird **innerhalb** `AiClassifier` gefangen, auf Warning-Level geloggt

(EventId 3010) und an `KeywordClassifier` als harten Boden delegiert. Der Consumer sieht in beiden Fällen ein gültiges Ergebnis — er bekommt nie eine Exception aus dem Classifier-Port. KI-Ausfall degradiert die Klassifikations-*Qualität*, nicht die *Verfügbarkeit*.




6.5 Skill-Routing — Erfolg

`SkillRoutingConsumer` löst die `ISkillIntegration` per exaktem `Name == MatchedSkill` auf. Kein registrierter Adapter → synchroner Terminal-Zustand `Unhandled` (kein Fault-Observer-Pfad).



6.6 Skill-Routing — Retry-Erschöpfung → Fault-Observer

Wirft `WriteAsync` bei jedem Versuch, erschöpft MassTransit das Retry-Budget ([500ms, 2s, 5s]) und publiziert `Fault<CaptureClassified>`. Der `LifecycleFaultObserver` (registriert **ohne** Retry-Policy, sonst Endlos-Loop) markiert den Capture `Unhandled` mit Grund aus der ersten Exception. Best-Effort: wirft `MarkUnhandledAsync` selbst, wird der Fehler geschluckt (Error, EventId 1003), um keine `Fault<Fault<T>>`-Rekursion auszulösen.



Ein steckengebliebener `Unhandled`-Capture kann über `POST /api/v1/captures/{id}/retry` neu eingereicht werden (re-published `CaptureCreated`, Lifecycle zurück auf `Raw`).

6.7 Fehler- und Retry-Semantik (Zusammenfassung)

- **Per-Consumer-Retry** (ADR 0003): Enrichment [100ms, 500ms] ; Embedding + Routing [500ms, 2s, 5s] .
- **Fault-Observer:** `LifecycleFaultObserver` bildet jeden Fault auf den passenden Terminal-Zustand ab — `Fault<CaptureCreated>` → `Orphan` , `Fault<CaptureClassified>` → `Unhandled` (kein Retry auf den Fault selbst).
- **Embedding ist Best-Effort:** Provider-Fehler → Capture wird ohne Embedding gespeichert, die Suche degradiert auf den Nicht-Vektor-Pfad.

7. Verteilungssicht

7.1 Docker-Compose-Topologie

Service	Image / Build	Funktion
flowhub.web	Build aus source/FlowHub.Web/Dockerfile	Blazor-UI + Minimal-API-Host; Healthcheck /health/live
flowhub.migrations	Build aus docker/migrations/Dockerfile	Init-Job: führt efbundle vor App-Start aus (12-Factor XII)
postgres	pgvector/pgvector:pg17	Persistenz inkl. pgvector; pg_isready -Healthcheck
rabbitmq	rabbitmq:3-management-alpine	Message-Bus (Prod-Transport)
prometheus	prom/prometheus:latest	Scrap /metrics (7 d Retention)
grafana	grafana/grafana:latest	Dashboards (anonymer Viewer, provisioniert)

Nur `flowhub.web` wird beim Release gebaut und veröffentlicht; `FlowHub.Api` ist in den Web-Host gefaltet (ADR 0003, „as built“). Die Demo-Overlay-Compose-Datei (`demo/docker-compose.yml`) ergänzt live laufende Ziel-Dienste (Vikunja, Wallabag, paperless), einen 15-Minuten-Reset, Traefik-Labels mit Rate-Limit und eine Uptime-Kuma-Statusseite.

7.2 CI/CD

Workflow	Trigger	Schritte
ci.yml	jeder Push / PR auf main	restore → build (warnings-as-errors) → test (XPlat-Coverage) → Artefakte; gated Merge
release.yml	Tags v*	Image <code>flowhub.web</code> bauen, nach GHCR pushen, Release-Notes via git-cliff, GitHub-Release

Workfl ow	Trigger	Schritte
migrati ons.yml	Push auf <code>main</code> mit Migrations- Änderung	self-contained <code>efbundle</code> als 30-Tage- Artefakt

Automatisierungsgrenze: Build/Test, Image-Publishing und Migrations-Bundle sind automatisiert; das **Environment-Rollout** ist bewusst manuell (ein `docker compose up` -Runbook), kein Auto-Deploy-on-Tag (ADR-Begründung in `docs/ci-cd.md`).

8. Querschnittliche Konzepte

„Querschnittlich“ = übergreifend: Themen, die nicht zu einem einzelnen Baustein gehören, sondern viele zugleich betreffen. Der Begriff ist die deutsche *arc42*-Bezeichnung für „Crosscutting Concepts“.

8.1 KI-Integration (ADR 0004, 0007)

FlowHub setzt **zwei substantielle KI-Rollen** ein: **(1) LLM-gestützte Klassifikation und Anreicherung** (`AiClassifier` — Typ-/Skill-Erkennung, Titel, Tags) und **(2) Embedding-basierte semantische Suche** (`pgvector`). Beide sind durch **Guardrails** abgesichert (deterministischer `KeywordClassifier` -Fallback, Schema-Validierung von `MatchedSkill`) und durch **Human-in-the-Loop** (nicht zugeordnete oder fehlgeschlagene Captures landen in der Orphan-/Unhandled-Inbox und sind per `POST .../retry` erneut anstossbar).

Die KI ist über `Microsoft.Extensions.AI` (`IChatClient`) abstrahiert. Zwei Adapter sind verdrahtet — Anthropic (nativ via `Anthropic.SDK`) und OpenRouter (via `Microsoft.Extensions.AI.OpenAI`) — die Provider-Wahl läuft über `Ai__Provider` , ohne Code-Änderung. Die Klassifikation nutzt **strukturierte Ausgabe**: das Antwort-Schema wird aus einem DTO mit `AllowedValues` generiert, sodass der Provider `MatchedSkill` nur aus der erlaubten Menge liefern kann; der Code re-validiert das Ergebnis zusätzlich defensiv. Jede Provider-Exception wird innerhalb `AiClassifier` gefangen und auf `KeywordClassifier` zurückgeführt (Warning, EventId 3010) — KI-Ausfall senkt die Qualität, nicht die Verfügbarkeit. Kosten- und Latenz-Guards: `MaxOutputTokens = 300` , `Temperature = 0.2` , 10 s HTTP-Timeout.

8.2 Persistenz (ADR 0005, 0006)

EF Core 10 + Npgsql. Sechs Repository-Ports liegen im `FlowHub.Core`, die `Ef*Repository`-Adapter in `FlowHub.Persistence`; `EfCaptureService` komponiert die Repositories und exponiert **nie** den `DbContext` nach aussen. Listen nutzen Keyset-/Cursor-Pagination auf `(CreatedAt DESC, Id DESC)` mit auf `[1, 200]` geklammertem Limit. Entities sind `internal sealed` (+ `InternalsVisibleTo` für Tests), sodass die Domäne nicht durch EF-Mapping-Attribute verunreinigt wird. Die semantische Suche liegt als pgvector-Spalte mit HNSW-Cosine-Index auf **derselben** PostgreSQL — keine separate Vektor-Datenbank.

8.3 Asynchrones Messaging (ADR 0002, 0003)

MassTransit trägt die Pipeline; die Endpoint- bzw. Queue-Namen werden via `SetKebabCaseEndpointNameFormatter` im **kebab-case** vergeben — Kleinbuchstaben mit Bindestrichen, z. B. `capture-enrichment`, `skill-routing`. Der Transport ist umschaltbar: In-Memory in Dev/Test, RabbitMQ in Prod (`Bus__Transport`). Jeder Consumer hat seine eigene Retry-Policy; der `LifecycleFaultObserver` ist die zentrale Fault-Senke (Kapitel 6.6).

8.4 Beobachtbarkeit

OpenTelemetry instrumentiert ASP.NET Core und die .NET-Runtime; der Prometheus-Exporter liefert `/metrics` (`dotnet_*`- und `http_*`-Serien), Grafana ist provisioniert. Health-Endpunkte: `/health/live` und `/health/ready`. MEAI- (`gen_ai.*`) und MassTransit-Traces sowie der **OTLP**-Export (OpenTelemetry Protocol — das Wire-Format, um Traces/Metriken an einen Collector zu senden) sind **vorbereitet, im Abgabe-Build aber nicht aktiv** (ADR 0009) — siehe technische Schulden, Kapitel 11.

8.5 Logging-Policy (ADR 0008)

Serilog schreibt strukturiert nach stdout (12-Factor XI). Log-Aufrufe nutzen verpflichtend source-generierte `LoggerMessage` (Analyzer CA1848/CA1873). Eine **Allow-List** definiert loggbare Felder (`CaptureId`, `Stage`, `MatchedSkill`, `Dauern`...); verboten sind `Capture-Body`, `Title`, `Absender-Handles`, `Embeddings`, `Prompts/Responses` und `Secrets`. Ein `PiiScrubbingEnricher` greift als Defense-in-Depth; `ex.Message` wird nicht als Feld geloggt (nur der Exception-Typ). `EventId`-Namespace: 1xxx Pipeline, 2xxx Skills, 3xxx KI, 5xxx Persistenz, 9xxx Compliance.

8.6 Telemetry- & PII-Policy (ADR 0009)

Span-Tags sind auf eine `flowhub.*` -Allow-List mit ausschliesslich Low-Cardinality-Werten beschränkt; High-Cardinality-Grössen landen in Histogrammen/Countern statt als Tags. Ein `TagAllowListProcessor` plus `FlowHubActivitytags` -Helper setzen das im Code durch.

8.7 Fehlerbehandlung

Alle API-Fehler werden als RFC 9457 ProblemDetails serialisiert (stabile `type` -URLs je Fehlerklasse). FluentValidation prüft an der API-Boundary und liefert maschinenlesbare Validierungsfehler.

8.8 Teststrategie

TDD ist nicht verhandelbar (`CLAUDE.md`). Die Schichten: bUnit für Blazor-Komponenten, NSubstitute für Mocks, FluentAssertions, xUnit; **Testcontainers gegen echtes PostgreSQL** für Repository-Tests (kein In-Memory-Provider-Drift); Playwright für E2E; Live-KI-Tests sind trait-gegatet (`[Trait("Category", "AI")]`) und aus der Default-Suite ausgeschlossen. Abgabestand: **294 Offline-Tests grün, 0 Fehler, 0 übersprungen**. Volltext und Reconciliation-Tabelle in `docs/spec/testing-strategy.md` .

9. Architekturentscheidungen (ADR)

Volltext je ADR in `docs/adr/` . Alle neun ADRs haben den Status *Accepted* — d. h. die Entscheidung wurde getroffen und ist in der Lösung umgesetzt (im Gegensatz zu *Proposed*, *Rejected* oder *Superseded*).

ADR	Titel	Entscheidung (Kurz)
0001	Frontend Render Mode & Architecture	Blazor Interactive Server; UI ruft Services in-process (kein REST für UI); OIDC/Authentik; flaches <code>source/</code> -Layout; Web ist selbst ein Channel
0002	Service Architecture &	Modularer Monolith (logischer, kein physischer Split); MassTransit-Bus; ausgehende Integrationen synchron in Consumern; kein gRPC; <code>/api/v1</code>

A D R	Titel	Entscheidung (Kurz)
	Async Communication	
00 03	Async Pipeline (MassTransit)	Zwei Events (<code>CaptureCreated</code> , <code>CaptureClassified</code>); Per-Consumer-Retry; <code>LifecycleFaultObserver</code> ; Kebab-Queue-Namen
00 04	AI Integration — Provider-Abstraktion	MEAI <code>IChatClient</code> ; Anthropic + OpenRouter; strukturierte Ausgabe; Keyword-Fallback
00 05	Persistence — EF Core + PostgreSQL	EF Core 10, Code-First-Migrations, Cursor-Pagination, interne Entities, Migrations als Init-Container
00 06	Vector Search — pgvector + Embeddings	pgvector auf bestehender Postgres, HNSW-Cosine, Embedding off-request-path; OpenAI-kompatibler Provider via ENV
00 07	LLM Hosting	<i>Ziel:</i> lokales Ollama als Default, Cloud als expliziter Opt-in — noch nicht umgesetzt, Cloud ist Live-Default
00 08	Logging Policy	Kein PII/Capture-Body im Log; source-gen <code>LoggerMessage</code> ; Allow-List + Scrubber
00 09	Telemetry & PII Policy	OTel-Span-Tag-Allow-List (<code>flowhub.*</code>), Low-Cardinality; Tracing im Abgabe-Build noch nicht aktiv

Projektbeschreibung §7 listet zusätzlich die frühen Plattform-/Strategie-Entscheidungen (PE-1...PE-7), entkoppelt von den Implementierungs-ADRs.

10. Qualitätsanforderungen

SMART-Anforderungen aus `docs/spec/nfa.md` :

ID	Kategorie	Ziel	Messung
Nf A-01	Performance	Capture-Listen-Abfrage (Limit ≤ 50) p95 < 100 ms	OTel-Span-Dauer auf <code>ListAsync</code> ; Testcontainers mit 10k Zeilen
Nf A-02	Performance	B-Tree-Index auf jeder häufigen Filterspalte	<code>HasIndex</code> im Modell + Migration; <code>EXPLAIN</code> zeigt Index-Scans
Nf A-03	Betriebbarkeit	Code-First-Migrations, idempotentes SQL via Init-Container, kein Auto-Migrate	Migrationsdateien; <code>migrations script --idempotent</code> ; Init-Container
Nf A-04	Skalierbarkeit	Volumen-Obergrenzen (Captures ≤ 100k, HealthSamples ≤ 10k/Integration, SkillRuns ≤ 500k)	dokumentiert; Lasttest seedet 10k Zeilen
Nf A-05	Zuverlässigkeit	Npgsql-Pool + transiente Retries	Data-Source-Optionen; Integrationstests
Nf A-D1	Deployment	Image-Cold-Build < 5 min	<code>release.yml</code> -Build-Schritt ≤ 300 s
Nf A-D2	Deployment	Veröffentlichtes Image < 200 MB komprimiert	GHCR-Layer-Größen
Nf A-D3	Deployment	<code>/health/live</code> < 30 s nach Cold-Start	Compose-Healthcheck 10 s × 3
Nf A-O1	Beobachtbarkeit	Prometheus <code>/metrics</code> exponiert	<code>curl /metrics</code> → 200, <code>dotnet_*</code> + <code>http_*</code>
Nf A-	Datenschutz	Verarbeitung nur auf eigener Infrastruktur; LLM lokal (Ollama)	<code>OutboundCallAuditTests</code> — heute nicht erfüllt

ID	Kategorie	Ziel	Messung
P1	(Ziel)		(Cloud aktiv)
NfA-P2	Datenschutz (Ziel)	KI-klassifizierte Captures sichtbar gekennzeichnet + Provenienz	Badge-Test + Migration + API-Felder — nicht gebaut

11. Risiken und technische Schulden

Punkt	Art	Status / Mitigation
EF-Outbox nicht verdrahtet	Tech. Schuld	Crash zwischen Persist und Publish kann einen Capture in <code>Raw</code> zurücklassen; Mitigation: manueller Retry-Endpunkt + Dashboard-Sichtbarkeit (ADR 0003)
OTLP-Tracing / KI-Metriken nicht aktiv	Tech. Schuld	Im Abgabe-Build deaktiviert; Allow-List/Helper vorbereitet (ADR 0009)
NfA-P1 / NfA-P2 offen	Ziel offen	Cloud-LLM + Cloud-Embeddings sind Live-Default; kein lokaler Ollama-Adapter, keine KI-Badges und keine Provenienz-Spalten — also keine Herkunfts-Felder wie <code>ClassificationSource</code> (KI / Heuristik / Manuell), <code>ClassifiedAt</code> , <code>ConfidenceScore</code> , die festhalten, wie ein Capture klassifiziert wurde
Compliance-Audit-Tests geplant	Tech. Schuld	<code>SerilogPiiAuditTests</code> , <code>TracingPiiAuditTests</code> , <code>OutboundCallAuditTests</code> als Block-5/geplant markiert
Semantische Suche	Bewusste Einsc	Self-hosted Embedder getestet, dann entfernt (schwache Trennschärfe auf kleinem Datensatz);

Punkt	Art	Status / Mitigation
auf Demo zurückgerollt	hränkung	/search → 503; Pipeline + Tests bleiben als Deliverable (ADR 0006 Amendment)
Idempotenz-Receiver fehlt	Tech. Schuld	RabbitMQ-At-least-once-Redelivery nicht abgesichert
Scope Creep (zu viele Skills)	Projektrisiko	Schlanke MVP-Liste, Future klar abgegrenzt
Ollama zu langsam (kein GPU)	Projektrisiko	Cloud-Fallback + Keyword-Baseline
Zeitdruck (Abgabe Juli)	Projektrisiko	MVP bewusst schlank, Future-Features dokumentiert

12. Glossar

Begriff	Bedeutung
Capture	Eingehender Informationsschnipsel (URL, Text, Datei); Aggregat-Root mit Lifecycle-Stage, Source, MatchedSkill, Tags, Title, ExternalRef, Embedding
Skill	Kategorie/Handler für einen Capture-Typ; routet zu genau einem Ziel-Dienst. Ist-Mechanismus: MatchedSkill-String auf eine ISkillIntegration.Name abgebildet
Channel	Eingangs-Quelle für Captures (Web Quick-Capture, REST-API; Telegram geplant). Die Web-UI ist selbst ein Channel (ADR 0001)
Integration	Ausgehender Adapter zu einem Ziel-Dienst (ISkillIntegration); verdrahtet: Wallabag, Vikunja

Begriff	Bedeutung
Lifecycle- Stages	Raw → Classified → Routed → Completed ; Fehler-Terminale Orphan und Unhandled (beide retry-bar)
MEAI	Microsoft.Extensions.AI — Provider-Abstraktion für LLMs in .NET
EF Core	Entity Framework Core — .NET-ORM
Blazor SSR	Server-seitiges Rendering mit Blazor
Homelab	Selbst betriebene Server-Infrastruktur (Proxmox)

Abkürzungen

Kürzel	Bedeutung
MEAI	Microsoft.Extensions.AI — Provider-Abstraktion für LLMs in .NET
ORM	Object-Relational Mapper (hier EF Core) — bildet Objekte auf DB-Tabellen ab
DI	Dependency Injection — Abhängigkeiten werden injiziert statt selbst erzeugt
SSR / CSR	Server-Side / Client-Side Rendering
OIDC / SSO	OpenID Connect / Single Sign-On — Authentifizierung über einen zentralen Identity-Provider (Authentik)
pgvector	PostgreSQL-Erweiterung für Vektor-Spalten + Ähnlichkeitssuche
HNSW	Hierarchical Navigable Small World — Approximate-Nearest-Neighbour-Index für Vektorsuche
OTLP	OpenTelemetry Protocol — Wire-Format zum Senden von Traces/Metriken an einen Collector
GHCR	GitHub Container Registry — hostet die veröffentlichten Docker-Images

Kürzel	Bedeutung
RFC 9457	Standard für maschinenlesbare HTTP-Fehler („Problem Details“)
DTO	Data Transfer Object — einfaches Datenobjekt für die Übertragung über eine Grenze

Arc42 v2.0 (as built), Juni 2026. Erstellt mit Unterstützung von Claude (Anthropic) gemäss den FFHS-Richtlinien für KI-Einsatz in Projektarbeiten.