

FlowHub – Arc42

Architekturdokumentation

CAS AI-Assisted Software Engineering (AISE) · W4B-C-AS001 · ZH-Sa-1 · FS26 **Student:** Andreas Imboden **Version:** 2.0 (as built) · **Stand:** Juni 2026 · **Template:** arc42 v8 (adaptiert)

Hinweis zur Version. Version 1.0 (Februar 2026) dokumentierte die *geplante* Konzept-Architektur zu Projektbeginn. Diese Version 2.0 beschreibt die **tatsächlich gebaute** Lösung am Abgabestand und kennzeichnet bewusst, wo das Konzept (Zielbild) über das Umgesetzte hinausgeht. Die Quell-Artefakte (Projektbeschreibung, ADRs 0001–0009, Design-Dokumente) liegen im Repository: <https://github.com/freaxnx01/FlowHub-CAS-AISE>.

 **Navigation:** Das Inhaltsverzeichnis dieses PDFs liegt als **Lesezeichen / Outline** vor — im PDF-Viewer über die Seitenleiste erreichbar (Adobe Acrobat: *Lesezeichen*; Edge/Chrome: *Inhalt/Document outline*).

1. Einführung und Ziele

FlowHub ist eine **KI-gestützte persönliche Inbox**. Sie nimmt Informationsschnipsel aus dem Alltag entgegen (ein Film-Tipp, ein Fachartikel, ein Beleg-Foto, eine Notiz), **erkennt und klassifiziert** sie automatisch und **leitet sie an den passenden Ziel-Dienst** weiter — ohne dass der Benutzer im Moment der Erfassung entscheiden muss, wohin die Information gehört.

Das adressierte Kernbedürfnis ist „**Capture without friction**“: Statt der heutigen fünf Schritte (Idee → App-Wahl → App öffnen → Kategorisieren → Ablegen) reduziert FlowHub die Erfassung auf einen einzigen Schritt. Die Klassifikation übernimmt ein **Skill-basiertes Routing-System**: ein LLM klassifiziert den Schnipsel, deterministisches Keyword-/URL-Muster-Matching dient als Fallback.

1.1 Aufgabenstellung

- **Funktional:** Captures über mehrere Kanäle entgegennehmen, automatisch klassifizieren, an den passenden externen Dienst routen und den

Lebenszyklus jedes Captures (inkl. Fehlerfälle und Retry) nachvollziehbar machen.

- **Qualitativ:** saubere, begründete Architektur (Modular Monolith, hexagonal), dokumentierte Architekturentscheidungen (ADRs) und eine reflektierte, KI-unterstützte Entwicklungsweise.
- **Rahmen:** Umsetzung inkrementell über die fünf CAS-Blöcke (Einführung, Frontend, Service, Persistence, Deployment).

KI-Nutzen je Kernfunktion (ein Satz pro Funktion):

- **Erfassung:** KI macht die Ein-Schritt-Erfassung möglich — der Nutzer muss im Moment des Capture nicht entscheiden, wohin die Information gehört.
- **Klassifikation:** ein LLM erkennt Typ und Ziel-Skill des Captures, mit deterministischem Keyword-Matching als Fallback.
- **Anreicherung:** das LLM ergänzt Titel und Tags, die der Nutzer sonst manuell setzen müsste.
- **Routing:** profitiert direkt von der KI-Klassifikation — der richtige Ziel-Dienst wird ohne Nutzer-Entscheid gewählt.
- **Semantische Suche:** Embeddings erlauben Suche nach Bedeutung statt nach exakten Stichwörtern.

1.2 Qualitätsziele

Die Qualitätsziele sind als SMART-Anforderungen in `docs/spec/nfa.md` spezifiziert (Volltext-Tabelle in Kapitel 10). Die fünf tragenden Ziele:

Tabelle 1: Qualitätsziele (Auszug)

Priorität	Qualitätsziel	Konkretisierung
1	Performance	Capture-Listen-Abfrage (Limit ≤ 50) p95 < 100 ms (NfA-01); B-Tree-Indizes auf allen häufigen Filterspalten (NfA-02).
2	Betriebbarkeit	Migrations-first, idempotentes SQL als Init-Container, nie Auto-Migrate in <code>app.Run()</code> (NfA-03).
3	Zuverlässigkeit	Npgsql-Connection-Pooling + transiente Retry-Policy (NfA-05); Retry + Fault-Observer in der Async-Pipeline.

Priorität	Qualitätsziel	Konkretisierung
4	Beobachtbarkeit	Prometheus- <code>/metrics</code> -Endpoint, <code>dotnet_*</code> - und <code>http_*</code> -Serien (NfA-O1).
5	Datenschutz (Ziel)	Verarbeitung möglichst auf eigener Infrastruktur (NfA-P1), KI-Transparenz/Provenienz (NfA-P2) — noch nicht umgesetzt , siehe Kapitel 11.

1.3 Stakeholder

Tabelle 2: Stakeholder

Stakeholder	Rolle	Erwartung an die Architektur
Homelab-Operator (Primärnutzer)	Betreibt FlowHub selbst (Proxmox/Docker), nutzt bereits Vikunja, Wallabag, paperless-ngx	Reibungslose Erfassung; self-hostbar; nachvollziehbarer Verbleib jeder Information
„Digital Hoarders“ (Sekundär)	Sammeln viel, ohne abzulegen	Niedrigschwellige Erfassung
CAS-/FFHS-Dozenten (Bewertung)	Beurteilen die Projektarbeit	Verteilte Web-App mit KI, saubere Architektur, ADRs, KI-Einsatz-Reflexion

FlowHub ist bewusst ein **Single-Operator-System**, keine Multi-User-Plattform (siehe Abgrenzung, Kapitel 11 / Projektbeschreibung §10).

1.4 Anwendungsfälle (Überblick)

Die funktionalen Anforderungen sind als 18 Anwendungsfälle (UC-01...UC-18) — mit Akteur, Auslöser, Vorbedingung, Ablauf, Nachbedingung, Fehlerfällen und Akzeptanzkriterien (inkl. prüfendem Test) — vollständig in `docs/spec/use-cases.md` spezifiziert. Den Überblick gibt Tabelle 3; **fünf Kernfunktionen** sind in

Kap. 1.5 mit der vollen Struktur direkt in diesem Dokument ausformuliert. Status:
 gebaut ·  geplant:

Tabelle 3: Anwendungsfälle (UC-Überblick)

UC	Anwendungsfall	Akteur	Status
UC-01	Capture via Web-UI erfassen (Quick)	Operator	
UC-02	Capture via Web-UI erfassen (Langform)	Operator	
UC-03	Capture via Telegram erfassen	Operator	
UC-04	Capture-Health im Dashboard überwachen	Operator	
UC-05	Captures durchsuchen & filtern	Operator	
UC-06	Fehlgeschlagenen Capture inspizieren & behandeln	Operator	
UC-07	Skill- & Integration-Health einsehen	Operator	
UC-08	Capture via REST-API erfassen	Nicht-UI-Client	
UC-09	Capture KI-klassifizieren & routen (Async-Pipeline)	System	
UC-10	Graceful Fallback auf Keyword-Klassifikation	System	
UC-11	Fehlgeschlagenen Capture per Dashboard erneut routen	Operator	
UC-12	Captures nach Lifecycle-Stage filtern	Operator	
UC-13	Captures nach Tag filtern	Operator	

UC	Anwendungsfall	Akteur	Status
UC-14	Captures nach Inhalt/Titel suchen	Operator	✓
UC-15	Skill-Run-Historie eines Captures ansehen	Operator	✓
UC-16	Integration-Health-Historie ansehen	Operator	✓
UC-17	Deployment via Docker Compose	Operator	✓
UC-18	Semantische Suche über Captures (REST; Cloud-Embedding-Key nötig)	Operator	✓

1.5 Ausgewählte Anwendungsfälle (Detail)

Die folgenden fünf Kernfunktionen sind mit voller UC-Struktur (Akteur · Auslöser · Vorbedingung · Ablauf · Nachbedingung · Fehler · Akzeptanzkriterien) direkt im Dokument ausformuliert. Sie decken die operatorseitige Erfassung (UC-01), den programmatischen Eingangskanal (UC-08), die zentrale KI-Pipeline (UC-09), den KI-Fallback-Schutz (UC-10) und die Fehler-Wiedervorlage (UC-11) ab. Die übrigen 13 Anwendungsfälle stehen in identischer Struktur in `docs/spec/use-cases.md`.

UC-01 — Capture via Web-UI erfassen (Quick)

- **Akteur:** Operator
- **Auslöser:** Operator fügt eine URL ein oder tippt Text in das Quick-Capture-Feld der AppBar.
- **Vorbedingung:** Operator ist authentifiziert (`DevAuthHandler` in Dev, Authentik OIDC in Prod).
- **Ablauf:**
 - Operator gibt Inhalt in das Quick-Capture-Feld ein.
 - Operator drückt Enter oder klickt das Submit-Icon.
 - System legt einen neuen Capture mit `source = Web`, `stage = Raw` an.
 - System zeigt eine Erfolgs-Snackbar mit Link auf die Capture-Detailseite.
 - Das Eingabefeld leert sich für die nächste Eingabe.
- **Nachbedingung:** Ein neuer Capture mit `LifecycleStage.Raw` existiert.

- **Fehler:** Leerer Inhalt → Inline-Hinweis „Type something first“; kein Capture angelegt.
- **Fehler:** Service-Fehler → Snackbar „Capture failed: {reason}“, Feldinhalt bleibt erhalten.
- **Akzeptanzkriterien:**
 - Nach Enter erscheint binnen 2 s eine `Captured ✓`-Snackbar (Playwright `HappyFlowTests.QuickCapture_TodoEntry_AppearsInCapturesListAndDetail`).
 - Die erfasste Zeile erscheint auf `/captures`, die Detailseite zeigt denselben Inhalt.
 - Leerer Inhalt → keine Zeile, Inline-Hinweis sichtbar.

UC-08 — Capture via REST-API erfassen

- **Akteur:** Nicht-UI-Client (Automations-Skript, Telegram-Bot-Modul, künftiger Mobile-Client)
- **Auslöser:** Client sendet `POST /api/v1/captures` mit JSON-Body.
- **Vorbedingung:** Client hält ein gültiges Bearer-Token (Dev-Bypass in Dev; Authentik-OIDC-Token in Prod).
- **Ablauf:**
 - Client sendet `POST /api/v1/captures` mit `{ "content": "...", "source": "Telegram|Web|Api", "skillOverride": "<SkillId|null>" }`.
 - FluentValidation an der API-Grenze prüft: `content` nicht leer, `source` ist ein bekannter Enum-Wert. Bei Fehler → `400 Bad Request` als RFC 9457 `ProblemDetails` (`type` -URI aus `FlowHubProblemTypes`).
 - Application-Service legt einen `Capture` mit `stage = Raw` an und persistiert ihn.
 - Service publiziert das Event `CaptureCreated` auf dem internen Bus.
 - API antwortet `201 Created` mit `Location: /api/v1/captures/{id}` und dem vollständigen `Capture`-Body.
- **Nachbedingung:** Ein `Capture` mit `LifecycleStage.Raw` existiert; `CaptureCreated` liegt auf dem Bus und stösst die Async-Pipeline (UC-09) an.
- **Fehler:** Fehlender/ungültiger `content` → `400 ProblemDetails` mit `errors` -Map.
- **Fehler:** Unbekannter `source` -Wert → `400 ProblemDetails`.
- **Fehler:** Auth fehlt/ungültig → `401 Unauthorized`.
- **Akzeptanzkriterien:**
 - Gültiger Body → 201 binnen NfA (`p95 < 200 ms` serverseitig); verifiziert durch `just smoke-prod` Schritt [5/6] und

tests/FlowHub.Api.IntegrationTests/.

- Response-Body entspricht dem `Capture`-Schema; `Location`-Header vorhanden.
- Fehlender `content` / unbekannter `source` → 400 ValidationProblem (`type = validation.md`).

UC-09 — Capture KI-klassifizieren & routen (Async-Pipeline)

- **Akteur:** System (keine menschliche Interaktion)
- **Auslöser:** Event `CaptureCreated` auf dem MassTransit-In-Process-Bus.
- **Vorbedingung:** Capture in `Raw`-Stage; MassTransit-Bus läuft.
- **Ablauf:**
 - i. Bus liefert `CaptureCreated` an `CaptureEnrichmentConsumer`.
 - ii. Consumer ruft `IClassifier.ClassifyAsync(capture)`.
 - iii. Ist ein Provider-Key konfiguriert, sendet `AiClassifier` den Inhalt an das LLM (`MaxOutputTokens=300` , `Temperature=0.2`); sonst direkt `KeywordClassifier`.
 - iv. `IClassifier` liefert ein `ClassificationResult` mit `MatchedSkill` (nullable) und Tags.
 - v. Consumer setzt `stage = Classified` und publiziert `CaptureClassified`.
 - vi. `SkillRoutingConsumer` löst die `ISkillIntegration` per `Name == MatchedSkill` auf. Treffer → `HandleAsync`, bei Erfolg `stage = Routed` → `Completed`; kein Treffer → `stage = Orphan`.
 - vii. Bei Integration-Fehler greift die MassTransit-Retry-Policy (NfA-10); nach Erschöpfung setzt `LifecycleFaultObserver` `stage = Unhandled` mit `FailureReason`.
- **Nachbedingung:** Capture erreicht einen Terminal-Zustand (`Completed` , `Orphan` oder `Unhandled`); Dashboard-Zähler aktualisieren beim nächsten Laden.
- **Fehler:** Provider-Fehler → deterministischer Fallback (UC-10), kein Pipeline-Abbruch.
- **Fehler:** Kein passender Adapter → `Unhandled` nach Retry-Erschöpfung.
- **Akzeptanzkriterien:**
 - URL-Capture erreicht `Completed` mit `MatchedSkill = "Wallabag"` und nicht-leerem `ExternalRef` (`Skills.ContractTests + just test-beta`).
 - Todo-Capture erreicht `Completed` mit `MatchedSkill = "Vikunja"` und nicht-leerem `ExternalRef`.

- MassTransit-Harness-Tests (`tests/FlowHub.Web.ComponentTests/Pipeline/*`) belegen die Consumer-Hops in Reihenfolge.

UC-10 — Graceful Fallback auf Keyword-Klassifikation

- **Akteur:** System (keine menschliche Interaktion)
- **Auslöser:** `AiClassifier.ClassifyAsync` läuft in einen Fehler: Netzwerk-Exception, HTTP-Timeout, JSON-Parse-Fehler, Schema-Verletzung oder generische Exception.
- **Vorbedingung:** AI-Provider konfiguriert; `CaptureEnrichmentConsumer` verarbeitet ein `CaptureCreated`.
- **Ablauf:**
 - `AiClassifier.ClassifyAsync` führt den LLM-Aufruf in einem try/catch über alle Exception-Typen aus.
 - Bei einer Exception loggt `AiClassifier` auf Warning mit EventId `3010` (`AiClassifierFellBackToKeyword`), inkl. Exception-Message und Capture-Id.
 - `AiClassifier` delegiert sofort an `KeywordClassifier.ClassifyAsync` und liefert dessen Ergebnis (`Title = null`).
 - `CaptureEnrichmentConsumer` fährt normal fort — er erhält ein gültiges `ClassificationResult`, unabhängig vom erzeugenden Classifier.
- **Nachbedingung:** Der Capture ist stets klassifiziert; ein Provider-Ausfall mindert die Qualität, verursacht aber keinen Verfügbarkeitsverlust. Das Warning-Log (EventId 3010) liefert operative Sichtbarkeit.
- **Fehler:** `AiClassifier` wirft nie an den Aufrufer — `ClassifyAsync` liefert immer ein `ClassificationResult`.
- **Akzeptanzkriterien:**
 - Mit absichtlich ungültigem `Ai__OpenRouter__ApiKey` erreicht ein Capture (UC-08) dennoch `Classified` — via `KeywordClassifier` (`tests/FlowHub.Web.ComponentTests/Ai/AiClassifierTests.cs`).
 - EventId `3010` `AiClassifierFellBackToKeyword` wird auf Warning mit Exception-Typ und Capture-Id geloggt.
 - `AiClassifier.ClassifyAsync` wirft unter keinen Umständen an den Aufrufer.

UC-11 — Fehlgeschlagenen Capture per Dashboard erneut routen

- **Akteur:** Operator
- **Auslöser:** Operator öffnet die Detailseite (`/captures/{id}`) eines `Orphan / Unhandled` -Captures und klickt „Retry“.

- **Vorbedingung:** Capture in `Orphan` - oder `Unhandled` -Stage; Operator authentifiziert.
- **Ablauf:**
 - UI ruft `POST /api/v1/captures/{id}/retry` .
 - Application-Service setzt `stage = Raw` zurück und löscht `FailureReason` .
 - Service publiziert ein neues `CaptureCreated` für dieselbe Capture-Id.
 - Die volle Async-Pipeline (UC-09) läuft erneut von vorn.
 - API antwortet `202 Accepted` ; UI zeigt Snackbar „Capture queued for retry“ und lädt die Detailseite neu.
- **Nachbedingung:** Der Capture durchläuft die Enrichment-Pipeline erneut; die Lifecycle-Stage wird abhängig vom Ergebnis erneut auf `Routed` , `Orphan` oder `Unhandled` gesetzt.
- **Fehler:** Capture nicht gefunden → `404 ProblemDetails`.
- **Fehler:** Stage nicht retry-bar (`Raw` , `Classified` , `Completed`) → `409 Conflict ProblemDetails`.
- **Akzeptanzkriterien:**
 - `POST .../retry` auf einem `Orphan` → `202 Accepted`, Body zeigt `stage = Raw` , `failureReason = null` (`tests/FlowHub.Api.IntegrationTests/CaptureRetryEndpointTests.cs`).
 - Derselbe Aufruf auf einem `Completed` → `409` (`type = capture-not-retryable.md`).
 - Derselbe Aufruf mit unbekannter Id → `404` (`type = capture-not-found.md`).

2. Randbedingungen

2.1 Technische Randbedingungen

Bereich	Festlegung
Plattform	.NET 10 / C# / ASP.NET Core (LTS)
Frontend	Blazor Web App (Interactive Server) + MudBlazor als einzige Komponenten-Bibliothek
API	ASP.NET Core Minimal APIs, versioniert unter <code>/api/v1</code> , Fehler als RFC 9457 ProblemDetails

Bereich	Festlegung
Persistenz	EF Core 10 + PostgreSQL 17 (Image <code>pgvector/pgvector:pg17</code>); Code-First-Migrations
Messaging	MassTransit (In-Memory in Dev/Test, RabbitMQ in Prod via <code>Bus__Transport</code>)
KI-Abstraktion	Microsoft.Extensions.AI (<code>IChatClient</code>); Provider via <code>Ai__Provider</code> wechselbar
Build/Betrieb	Multi-Stage-Dockerfile (<code>sdk:10.0-alpine</code> → <code>aspnet:10.0-alpine</code> , non-root), Docker Compose
Konventionen	Warnings-as-Errors, Nullable Reference Types, SemVer, Conventional Commits, 12-Factor

2.2 Organisatorische Randbedingungen

- **CAS-Struktur:** fünf FFHS-Blöcke (1 Konzept, 2 Frontend, 3 Service/REST, 4 Persistence, 5 Deployment), Abgabe Juli 2026. Jeder Block schliesst mit einer dokumentierten Nachbereitung ab, die gegen die Moodle-Bewertungskriterien selbst geprüft wird.
- **Dokumentation:** arc42 als Architektur-Vorlage; Architekturentscheidungen als ADRs (Kapitel 9).
- **Stack-Wahl:** Die freie Technologie-Wahl wurde in der PVA bestätigt. Wo der Kurs einen Quarkus-/Jakarta-EE-Stack als Beispiel nennt, setzt FlowHub funktionale .NET-Äquivalente ein (EF Core ↔ Hibernate/Panache, MassTransit ↔ Queue-basiertes Messaging, MEAI ↔ Spring-AI). Das Programmierkriterium der Rubrik ist seit dem Update Juni 2026 framework-neutral.

3. Kontextabgrenzung

3.1 Fachlicher Kontext

FlowHub sitzt zwischen **Eingangs-Kanälen** und **Ziel-Diensten**:

- **Eingangs-Kanäle (gebaut):** Web Quick-Capture (Eingabefeld in der Blazor-AppBar) und REST-API `POST /api/v1/captures` . Ein **Telegram-Bot** ist

konzipiert, aber **nicht umgesetzt**.

- **Ziel-Dienste:** Wallabag (Read-Later), Vikunja (Tasks/Kanban) — beide als ISkillIntegration -Adapter **gebaut**; paperless-ngx (DMS) in der Live-Demo; Obsidian/Git Forge als Wissens-Ablage **geplant**. Fällt keine Zuordnung, bleibt der Capture in der FlowHub-Inbox (PostgreSQL).

Skill → Ziel-Dienst (Konzept-Mapping): Artikel → Wallabag; Homelab/Buch/Film → Vikunja; Dokument → paperless-ngx; Wissen/Zitat → Obsidian/Git Forge; generisch → Inbox. **Wired am Abgabestand:** Wallabag und Vikunja.

3.2 Technischer Kontext




Abbildung 1: System-Kontext (C4 Level 1)

Ist-Stand-Hinweis. Das Kontextdiagramm zeigt das Gesamtbild inkl. geplanter Bausteine. Am Abgabestand umgesetzt sind die sechs Projekte `FlowHub.{Web,Core,Api,AI,Persistence,Skills}` mit Wallabag- und Vikunja-Adapttern; **Telegram-Kanal, lokales Ollama, Authentik/OIDC und der Obsidian-Pfad sind geplant** (KI läuft heute über Cloud-Provider, Auth über Dev-Bypass). paperless-ngx ist nur in der Live-Demo angebunden.

Beziehung	Mechanismus
Operator → Web-UI	HTTP + SignalR (langlebiger Blazor-Interactive-Server-Circuit)
Web / API → Core	In-Process-DI (kein HTTP für UI-Daten, ADR 0001)
Core → KI-Provider	REST (Cloud: OpenRouter/Mistral heute; lokales Ollama als Ziel, ADR 0007)
Skills → externe Dienste	HTTP REST (Wallabag, Vikunja)
Web → Authentik (OIDC)	geplant — heute Dev-Bypass (<code>DevAuthHandler</code>)

4. Lösungsstrategie

Problem / Treiber	Lösungsansatz	Begründung / ADR
Klare Modulgrenzen ohne Microservice-Overhead	Modularer Monolith — ein deploybarer Prozess, Fähigkeiten als getrennte .NET-Projekte, modulübergreifende Aufrufe nur über Ports in <code>FlowHub.Core</code>	ADR 0001, ADR 0002
Testbarkeit, austauschbare Infrastruktur	Hexagonale Schichtung je Modul — Driving-Ports (<code>IClassifier</code> , <code>ICaptureService</code>) und Driven-Ports (<code>ISkillIntegration</code> , <code>Repositories</code>) im Core, Adapter in den Fähigkeits-Projekten	ADR 0002
Entkopplung Erfassung ↔ Verarbeitung, Resilienz	Asynchrone Pipeline über MassTransit (In-Memory in Dev, RabbitMQ in Prod); ausgehende Integrationen synchron innerhalb der Consumer	ADR 0002, ADR 0003

Problem / Treiber	Lösungsansatz	Begründung / ADR
Austauschbarkeit des LLM-Providers	KI-Provider-Abstraktion (MEAI <code>IClient</code>); Anthropic + OpenRouter; <code>KeywordClassifier</code> als deterministischer Fallback-Boden	ADR 0004
KI-Suche ohne separate Vektor-DB	pgvector auf derselben PostgreSQL statt zusätzlicher Infrastruktur	ADR 0006

5. Bausteinsicht

5.1 Ebene 1 — Module (Ist-Architektur)




Abbildung 2: Ist-Architektur — Bausteinsicht Ebene 1 (modularer Monolith)

Modul	Verantwortung
FlowHub. Core	Domänen-Typen (Capture , Skill , Health) + Driving-/Driven-Ports (IClassifier , IEmbeddingService , ISkillIntegration , Repository-Interfaces). Keine Infrastruktur-Referenzen.
FlowHub. Web	Blazor Web App (Interactive Server, MudBlazor) + MassTransit-Consumer (/Pipeline/) + Host des Minimal-API. Komponiert

Modul	Verantwortung
	FlowHub.Api in-process (kein separater Container).
FlowHub.Api	Minimal-API-Endpunkte (CaptureEndpoints , SearchEndpoints , AdminEndpoints) als In-Process-Library.
FlowHub.AI	AiClassifier + AiEmbeddingService über MEAI.
FlowHub.Persistence	EF Core + PostgreSQL + pgvector; sechs Ef*Repository - Implementierungen.
FlowHub.Skills	ISkillIntegration -Adapter für Wallabag und Vikunja.

Diese sechs Projekte bilden die vollständige FlowHub.slnx . Telegram-Kanal und generische Integrations-Schicht sind **geplant, nicht gescaffolded**.

5.2 Skill-System (Kernarchitektur)

- **IClassifier** (Driving-Port): ClassifyAsync(content) → ClassificationResult (Tags, MatchedSkill, Title?) . Zwei Adapter: KeywordClassifier (Regeln) und AiClassifier (MEAI; füllt zusätzlich Title).
- **ISkillIntegration** (Driven-Port): Name + HandleAsync(Capture) → SkillResult . Auflösung per exaktem Name == MatchedSkill .
- **SkillRoutingConsumer** ist der Dispatcher: kein Treffer → MarkUnhandledAsync (Capture bleibt in der Inbox).

5.3 Ebene 2 — MassTransit-Pipeline (5 Consumer)

Die Async-Pipeline ist die innere Zerlegung des Host-Prozesses. Jeder Consumer ist ein eigener Baustein mit klarer Verantwortung und eigener Retry-Policy:

Consumer	Reagiert auf	Verantwortung	Retry
CaptureEnrichmentConsumer	CaptureCreated	Klassifikation via IClassifier ; setzt Classified oder Orphan	[100ms, 500ms]
SkillRoutingConsumer	CaptureClassified	Auflösung ISkillIntegration per Name; Write; setzt	[500ms, 2s, 5s]

Consumer	Reagiert auf	Verantwortung	Retry
	d	Routed / Unhandled	
CaptureEmbeddingConsumer	CaptureCreated	Best-Effort-Embedding (pgvector); parallel zum Enrichment	[500ms, 2s, 5s]
CaptureNotificationConsumer	Lifecycle-Events	optionale ntfy.sh-Benachrichtigung	—
LifecycleFaultObserver	Fault<...>	bildet Faults auf Orphan / Unhandled ab (kein Retry)	keine

Zwei Events tragen die Pipeline: `CaptureCreated` (nach dem Submit) und `CaptureClassified` (nach erfolgreicher Klassifikation). Enrichment und Embedding hängen beide am `CaptureCreated` und laufen damit parallel.

5.4 Ebene 2 — Skill-System (Ports & Adapter)

```

Capture submitted
→ IClassifier.ClassifyAsync(content)           (Driving-Port)
    → ClassificationResult { MatchedSkill, Tags, Title? }
→ CaptureClassified (MassTransit-Event)
→ SkillRoutingConsumer
    → ISkillIntegration · Name == MatchedSkill (Driven-Port)
    → integration.HandleAsync(capture) → SkillResult

```

- **IClassifier** — zwei Adapter: `KeywordClassifier` (deterministische Regeln, immer `Title = null`) und `AiClassifier` (MEAI; füllt zusätzlich `Title`, fällt bei Provider-Fehlern auf `KeywordClassifier` zurück).
- **ISkillIntegration** — ein Adapter je Ziel-Dienst, jeder kapselt HTTP/Auth/Tagging selbst. Verdrahtet: `Wallabag`, `Vikunja`. Auflösung per exaktem `Name` - Match gegen `MatchedSkill`.
- **Einen Skill ergänzen** (Erweiterungspunkt): `ISkillIntegration` in `FlowHub.Skills/<Service>/` implementieren, in den DI-Extensions registrieren, dem Classifier den neuen `MatchedSkill` beibringen. Roadmap: paperless-ngx, Vikunja Kanban, Obsidian/Git Forge teilen denselben Vertrag.

5.5 Paketstruktur

Flaches Layout `source/FlowHub.<Capability>/` (ADR 0001). Keine Sibling-Projekt-Referenzen zwischen Fähigkeiten; jede Abhängigkeit läuft über einen Port in `FlowHub.Core`.

5.6 Datenmodell




Abbildung 3: Datenmodell (Entity-Relationship)

Captures ist das Aggregat-Root. Das **Embedding** (pgvector-Spalte mit **HNSW**-Index — *Hierarchical Navigable Small World*, ein Approximate-Nearest-Neighbour-Index für schnelle Vektor-Ähnlichkeitssuche — mit Cosine-Distanz) kam in Block 5 hinzu; auf der öffentlichen Demo sind Embeddings deaktiviert (`/search` → 503), siehe ADR 0006 (inkl. Amendment).

5.7 Schnittstellensicht — Interaktions-/Vertragsperspektive

Die Bausteinsicht (Abb. 2) zeigt die **Struktur** (welche Bausteine existieren), die Laufzeitsicht (Kap. 6) das **Verhalten** (zeitliche Abläufe). Die folgende Schnittstellensicht ist die dritte, eigenständige Perspektive: die **Interaktion** — die *Verträge* an den Baustein-Grenzen. Sie beantwortet nicht „was läuft wann ab“, sondern „welche Operation, über welches Protokoll, mit welcher Nutzlast und in welcher Richtung“ ein Baustein anbietet bzw. aufruft. Drei Vertragsarten reihen sich von aussen nach innen:

1. **REST-Vertrag** (synchron, extern): `FlowHub.Api` exponiert `/api/v1` als OpenAPI-3-Kontrakt (browsbar unter `/scalar`); jede Operation hat ein

typisiertes Request-/Response-Schema und meldet Fehler einheitlich als RFC 9457 ProblemDetails.

2. **Port-Vertrag** (synchron, in-process): Treiber- und getriebene Ports in FlowHub.Core (ICaptureService , IClassifier , ISkillIntegration , ICaptureRepository) — Methodensignaturen statt HTTP.
3. **Event-Vertrag** (asynchron): CaptureCreated und CaptureClassified als MassTransit-Nachrichtentypen entkoppeln Erfassung von Verarbeitung.




Abbildung 4: Schnittstellen-/Interaktionssicht — Vertrags-Kontrakte an den Baustein-Grenzen (REST, Ports, Events)

Lesehilfe. Jeder Pfeil trägt Protokoll, Operation und Richtung; die Kontrakt-Nummern (C1-C17) verweisen auf Tabelle 4, die Request-/Response-Nutzlast und Fehlerfälle je Schnittstelle ausformuliert. Diese Sicht ergänzt — und doppelt nicht — die Sequenzdiagramme: Kap. 6 zeigt die *Reihenfolge* der Aufrufe über die Zeit, Abb. 4 die *statischen Kontrakte* der Schnittstellen unabhängig vom Ablauf. Der vollständige REST-Vertrag ist als OpenAPI unter `/scalar` browsbar; die Port-Signaturen liegen in `FlowHub.Core`.

Tabelle 4: Schnittstellen-Verträge (Detail zu Abbildung 4)

Vertrag (Pfeil)	Protokoll · Operation	Request → Response / Fehler
C1 — Client → Api	HTTPS POST · <code>/api/v1/captures</code>	<code>{content, source}</code> → 201 Created + <code>Location</code> / 400 ProblemDetails
C2 — Client → Api	HTTPS GET · <code>/api/v1/captures</code>	Query <code>stage, tag, q</code> → 200 Capture-Liste
C3 — Client → Api	HTTPS GET · <code>/api/v1/captures/{id}</code>	→ 200 Capture / 404 ProblemDetails
C4 — Client → Api	HTTPS POST · <code>/api/v1/captures/{id}/retr y</code>	→ 202 Accepted / 404 / 409 ProblemDetails
C5 — Client → Api	HTTPS GET · <code>/api/v1/captures/search</code>	Query <code>q, limit</code> → 200 Treffer / 400 / 503 ProblemDetails
C6 — Client → Api	HTTPS GET · <code>/health/live</code> , <code>/health/ready</code>	→ 200 Healthy (Liveness / Readiness)
C7 — Api → Core	in-proc · <code>ICaptureService.SubmitAsyn c(content, source, ct)</code>	→ <code>CaptureId</code>
C8 — Api → Core	in-proc · <code>ICaptureService.RetryAsync (id, ct)</code>	→ void (publiziert neues <code>CaptureCreated</code>)

Vertrag (Pfeil)	Protokoll · Operation	Request → Response / Fehler
C9 — Api → Core	in-proc · ICaptureRepository.QueryAs ync / SearchAsync(filter, ct)	→ Capture-Liste
C10 — Core → Bus	publish · Event CaptureCreated	Capture-Id + Inhalt → Enrichment + Embedding
C11 — Bus → AiClassifier	consume · IClassifier.ClassifyAsync(content, ct)	→ ClassificationResult (MatchedSkill, Tags, Title)
C12 — AiClassifier → LLM	HTTPS REST · IChatClient chat/completions	Prompt → JSON-Schema- Antwort (MaxOutputTokens=300)
C13 — AiClassifier → Bus	publish · Event CaptureClassified	nur bei erfolgreicher Klassifikation
C14 — Bus → SkillIntegratio n	consume · ISkillIntegration.HandleAs ync(capture, ct)	Auflösung Name == MatchedSkill → SkillResult (Success, ExternalRef)
C15 — SkillIntegratio n → extern	HTTPS REST · POST entries/tasks (Bearer-Token)	Capture-Inhalt → ExternalRef
C16 — Core → Repository	in-proc · Repository-Port (ICaptureRepository u. a.)	EF-Core-Aufruf
C17 — Repository → DB	TCP 5432 · EF Core SQL + pgvector	Query / Write, Vektor-Suche per Cosine-Distanz

6. Laufzeitsicht

6.1 Capture-Lebenszyklus




Abbildung 5: Capture-Lebenszyklus (Zustandsdiagramm)

`Raw` → `Classified` → `Routed` → `Completed` ist der Happy Path; `Orphan` (kein Skill / Enrichment-Fault) und `Unhandled` (kein Adapter / Routing-Fault) sind die retry-baren Terminal-Zustände — beide kehren über den Retry-Endpunkt nach `Raw` zurück.

6.2 Hot-Path — Submit → Skill-Write




Abbildung 6: Hot-Path — Submit bis Skill-Write (Sequenz)

Wesentlich: Die HTTP-Antwort (201) erfolgt **vor** Klassifikation und Routing — der Submit-Pfad bleibt schnell, die teure Arbeit läuft asynchron. Enrichment und Embedding laufen parallel; das Embedding ist Best-Effort.

6.3 Enrichment — Happy Path (AI-Classifier erfolgreich)

Gilt, wenn `Ai__Provider` und der passende API-Key gesetzt sind. `AiClassifier` macht **einen** strukturierten Provider-Call, validiert das Schema und liefert `ClassificationResult(Tags, MatchedSkill, Title)`. Ein leerer `MatchedSkill` ist ein *gültiges* Ergebnis (→ `MarkOrphanAsync`), keine Exception.




Abbildung 7: Enrichment — Happy Path (Sequenz)

6.4 Enrichment — Fallback (Provider-Fehler → KeywordClassifier)

Jede Exception aus `IChatClient` (Netzwerk, Timeout, JSON-Parse, Schema-Verletzung) wird **innerhalb** `AiClassifier` gefangen, auf Warning-Level geloggt (EventId 3010) und an `KeywordClassifier` als harten Boden delegiert. Der Consumer sieht in beiden Fällen ein gültiges Ergebnis — er bekommt nie eine Exception aus dem Classifier-Port. KI-Ausfall degradiert die Klassifikations-*Qualität*, nicht die *Verfügbarkeit*.




Abbildung 8: Enrichment — Fallback auf KeywordClassifier (Sequenz)

6.5 Skill-Routing — Erfolg

`SkillRoutingConsumer` löst die `ISkillIntegration` per exaktem `Name == MatchedSkill` auf. Kein registrierter Adapter → synchroner Terminal-Zustand `Unhandled` (kein Fault-Observer-Pfad).




Abbildung 9: Skill-Routing — Erfolg (Sequenz)

6.6 Skill-Routing — Retry-Erschöpfung → Fault-Observer

Wirft `WriteAsync` bei jedem Versuch, erschöpft MassTransit das Retry-Budget ([500ms, 2s, 5s]) und publiziert `Fault<CaptureClassified>`. Der `LifecycleFaultObserver` (registriert **ohne** Retry-Policy, sonst Endlos-Loop) markiert den Capture `Unhandled` mit Grund aus der ersten Exception. Best-Effort: wirft `MarkUnhandledAsync` selbst, wird der Fehler geschluckt (Error, EventId 1003), um keine `Fault<Fault<T>>`-Rekursion auszulösen.




Abbildung 10: Skill-Routing — Retry-Erschöpfung & Fault-Observer (Sequenz)

Ein steckengebliebener `Unhandled`-Capture kann über `POST /api/v1/captures/{id}/retry` neu eingereicht werden (re-published `CaptureCreated`, `Lifecycle` zurück auf `Raw`).

6.7 Fehler- und Retry-Semantik (Zusammenfassung)

- **Per-Consumer-Retry** (ADR 0003): Enrichment [100ms, 500ms] ; Embedding + Routing [500ms, 2s, 5s] .
- **Fault-Observer:** LifecycleFaultObserver bildet jeden Fault auf den passenden Terminal-Zustand ab — Fault<CaptureCreated> → Orphan , Fault<CaptureClassified> → Unhandled (kein Retry auf den Fault selbst).
- **Embedding ist Best-Effort:** Provider-Fehler → Capture wird ohne Embedding gespeichert, die Suche degradiert auf den Nicht-Vektor-Pfad.

7. Verteilungssicht

7.1 Docker-Compose-Topologie

Service	Image / Build	Funktion
flowhub.web	Build aus source/FlowHub.Web/Dockerfile	Blazor-UI + Minimal-API-Host; Healthcheck /health/live
flowhub.migrations	Build aus docker/migrations/Dockerfile	Init-Job: führt efbundle vor App-Start aus (12-Factor XII)
postgres	pgvector/pgvector:pg17	Persistenz inkl. pgvector; pg_isready -Healthcheck
rabbitmq	rabbitmq:3-management-alpine	Message-Bus (Prod-Transport)
prometheus	prom/prometheus:latest	Scrap /metrics (7 d Retention)
grafana	grafana/grafana:latest	Dashboards (anonymer Viewer, provisioniert)

Zwei first-party Container, unabhängig gebaut und veröffentlicht. Im Release-Workflow (release.yml , Tag v*) werden **beide** Container-Images unabhängig voneinander aus dem gleichen Repo gebaut und nach GHCR gepusht — der laufende App-Container ghcr.io/freaxnx01/flowhub-web und der Init-Container ghcr.io/freaxnx01/flowhub-migrations (eigene Dockerfile + eigene Versionierung, gleiche SemVer-Tags). Damit ist die modular-monolithische Lösung

„klar abgegrenzt in Module bzw. Sub-Systeme strukturiert ... und als Container lauffähig betrieben" durch **zwei separat gepullbare, separat startbare, je eigenständig gebaute Container** belegbar (vgl. Rubrik *Bewertungskriterien Projektarbeit AISE*, Juni 2026, Kriterium 17). `FlowHub.Api` ist gemäss ADR 0003 „as built" in den Web-Host gefaltet. Die Demo-Overlay-Compose-Datei (`demo/docker-compose.yml`) ergänzt live laufende Ziel-Dienste (Vikunja, Wallabag, paperless), einen 15-Minuten-Reset, Traefik-Labels mit Rate-Limit und eine Uptime-Kuma-Statusseite.

7.2 CI/CD

Workfl ow	Trigger	Schritte
<code>ci.yml</code>	jeder Push / PR auf <code>main</code>	restore → build (warnings-as-errors) → test (XPlat-Coverage) → Artefakte; gated Merge
<code>release .yml</code>	Tags <code>v*</code>	Image <code>flowhub.web</code> bauen, nach GHCR pushen, Release-Notes via git-cliff, GitHub-Release
<code>migrati ons.yml</code>	Push auf <code>main</code> mit Migrations-Änderung	self-contained <code>efbundle</code> als 30-Tage-Artefakt

Automatisierungsgrenze: Build/Test, Image-Publishing und Migrations-Bundle sind automatisiert; das **Environment-Rollout** ist bewusst manuell (ein `docker compose up` -Runbook), kein Auto-Deploy-on-Tag (ADR-Begründung in `docs/ci-cd.md`).

8. Querschnittliche Konzepte

„Querschnittlich" = übergreifend: Themen, die nicht zu einem einzelnen Baustein gehören, sondern viele zugleich betreffen. Der Begriff ist die deutsche arc42-Bezeichnung für „Crosscutting Concepts".

8.1 KI-Integration (ADR 0004, 0007)

FlowHub setzt **zwei substanzielle KI-Rollen** ein: **(1) LLM-gestützte Klassifikation und Anreicherung** (`AiClassifier` — Typ-/Skill-Erkennung, Titel,

Tags) und **(2) Embedding-basierte semantische Suche** (pgvector). Beide sind durch **Guardrails** abgesichert (deterministischer `KeywordClassifier`-Fallback, Schema-Validierung von `MatchedSkill`) und durch **Human-in-the-Loop** (nicht zugeordnete oder fehlgeschlagene Captures landen in der Orphan-/Unhandled-Inbox und sind per `POST .../retry` erneut anstossbar).

Die KI ist über `Microsoft.Extensions.AI` (`IChatClient`) abstrahiert. Zwei Adapter sind verdrahtet — Anthropic (nativ via `Anthropic.SDK`) und OpenRouter (via `Microsoft.Extensions.AI.OpenAI`) — die Provider-Wahl läuft über `Ai__Provider`, ohne Code-Änderung. Die Klassifikation nutzt **strukturierte Ausgabe**: das Antwort-Schema wird aus einem DTO mit `AllowedValues` generiert, sodass der Provider `MatchedSkill` nur aus der erlaubten Menge liefern kann; der Code re-validiert das Ergebnis zusätzlich defensiv. Jede Provider-Exception wird innerhalb `AiClassifier` gefangen und auf `KeywordClassifier` zurückgeführt (Warning, EventId 3010) — KI-Ausfall senkt die Qualität, nicht die Verfügbarkeit. Kosten- und Latenz-Guards: `MaxOutputTokens = 300`, `Temperature = 0.2`, 10 s HTTP-Timeout.

8.2 Persistenz (ADR 0005, 0006)

EF Core 10 + Npgsql. Sechs Repository-Ports liegen im `FlowHub.Core`, die `Ef*Repository`-Adapter in `FlowHub.Persistence`; `EfCaptureService` komponiert die Repositories und exponiert **nie** den `DbContext` nach aussen. Listen nutzen Keyset-/Cursor-Pagination auf (`CreatedAt DESC`, `Id DESC`) mit auf `[1, 200]` geklammertem Limit. Entities sind `internal sealed` (+ `InternalsVisibleTo` für Tests), sodass die Domäne nicht durch EF-Mapping-Attribute verunreinigt wird. Die semantische Suche liegt als pgvector-Spalte mit HNSW-Cosine-Index auf **derselben** PostgreSQL — keine separate Vektor-Datenbank.

8.3 Asynchrones Messaging (ADR 0002, 0003)

MassTransit trägt die Pipeline; die Endpoint- bzw. Queue-Namen werden via `SetKebabCaseEndpointNameFormatter` im **kebab-case** vergeben — Kleinbuchstaben mit Bindestrichen, z. B. `capture-enrichment`, `skill-routing`. Der Transport ist umschaltbar: In-Memory in Dev/Test, RabbitMQ in Prod (`Bus__Transport`). Jeder Consumer hat seine eigene Retry-Policy; der `LifecycleFaultObserver` ist die zentrale Fault-Senke (Kapitel 6.6).

8.4 Beobachtbarkeit

OpenTelemetry instrumentiert ASP.NET Core, HttpClient, EF Core und die .NET-Runtime; der Prometheus-Exporter liefert `/metrics` (`dotnet_*`- und `http_*`-

Serien), Grafana ist provisioniert. Health-Endpunkte: `/health/live` und `/health/ready`.

Tracing ist aktiv (`Program.cs`): die `WithTracing(...)`-Pipeline trägt die ActivitySources `FlowHub`, `MassTransit` und `Experimental.Microsoft.Extensions.AI`, hinzu HTTP-/EF-Core-/ASP.NET-Core-Auto-Instrumentation. Der `TagAllowListProcessor` (ADR 0009 §1/§2/§4) läuft als `BaseProcessor<Activity>` vor den Exportern und strippt forbidden tags (HTTP-Bodies, `db.statement`, `gen_ai.prompt/completion`, `*.email` / `*.username` / `*.user.id`) sowie unbekannte `flowhub.*`-Keys; String-Werte

256 Zeichen werden zu `<redacted:length=N>`. Eigenwerte werden ausschliesslich über die Helper-Klasse

`FlowHub.Core.Telemetry.FlowHubActivityTags` gesetzt (ADR 0009 §5). Export: Console immer aktiv (im Build sichtbar); OTLP zusätzlich, sobald `Otlp__Endpoint` gesetzt ist — z. B. an einen Collector/Tempo/Jaeger. Der Audit-Test `TagAllowListProcessorTests` (ADR 0009 §6, 12 Fälle) verriegelt die Policy gegen Regressionen.

MEAI- (`gen_ai.*`) und MassTransit-Traces fliessen über die `WithTracing(...)`-Pipeline (ActivitySources `Experimental.Microsoft.Extensions.AI` und `MassTransit`); ein **OTLP**-Collector (OpenTelemetry Protocol — Wire-Format zum Senden von Traces an Tempo/Jaeger) wird durch Setzen von `Otlp__Endpoint` aktiviert.

8.5 Logging-Policy (ADR 0008)

Serilog schreibt strukturiert nach stdout (12-Factor XI). Log-Aufrufe nutzen verpflichtend source-generierte `LoggerMessage` (Analyzer CA1848/CA1873). Eine **Allow-List** definiert loggbare Felder (`CaptureId`, `Stage`, `MatchedSkill`, `Dauern` ...); verboten sind Capture-Body, Title, Absender-Handles, Embeddings, Prompts/Responses und Secrets. Ein `PiiScrubbingEnricher` greift als Defense-in-Depth; `ex.Message` wird nicht als Feld geloggt (nur der Exception-Typ). EventId-Namespace: 1xxx Pipeline, 2xxx Skills, 3xxx KI, 5xxx Persistenz, 9xxx Compliance.

8.6 Telemetry- & PII-Policy (ADR 0009)

Span-Tags sind auf eine `flowhub.*`-Allow-List mit ausschliesslich Low-Cardinality-Werten beschränkt; High-Cardinality-Grössen landen in Histogrammen/Countern

statt als Tags. Ein `TagAllowListProcessor` plus `FlowHubActivitytags` -Helper setzen das im Code durch.

8.7 Fehlerbehandlung

Alle API-Fehler werden als RFC 9457 ProblemDetails serialisiert (stabile `type` -URLs je Fehlerklasse). FluentValidation prüft an der API-Boundary und liefert maschinenlesbare Validierungsfehler.

8.8 Teststrategie

TDD ist nicht verhandelbar (`CLAUDE.md`). Die Schichten: bUnit für Blazor-Komponenten, NSubstitute für Mocks, FluentAssertions, xUnit; **Testcontainers gegen echtes PostgreSQL** für Repository-Tests (kein In-Memory-Provider-Drift); Playwright für E2E; Live-KI-Tests sind trait-gegatet (`[Trait("Category", "AI")]`) und aus der Default-Suite ausgeschlossen. Abgabestand: **294 Offline-Tests grün, 0 Fehler, 0 übersprungen**. Volltext und Reconciliation-Tabelle in `docs/spec/testing-strategy.md` .

Test der KI-Anteile (Guardrails, nicht nur Trait-Gating). Über das Ausschliessen der nicht-deterministischen Live-Aufrufe hinaus ist das *Ausfallverhalten* der KI deterministisch getestet (`AiClassifierTests`): fünf Fallback-Pfad-Tests prüfen, dass der `AiClassifier` bei HttpRequest-, TaskCanceled- und JSON-/Schema-Fehlern auf den `KeywordClassifier` zurückfällt, dabei `EventId 3010` (Warning) loggt und **nie eine Exception zum Aufrufer durchreicht**. Ergänzend prüft eine **Schema-Validierung** den `MatchedSkill` gegen die erlaubten Werte (`Wallabag` / `Vikunja` /leer) — eine ungültige Modell-Antwort wird verworfen statt geroutet. Das nicht-deterministische KI-Verhalten ist damit nicht bloss ausgeklammert, sondern an seinen Guardrails abgesichert.

8.9 Abnahmekriterien (Überblick)

Die Lösung ist gegen **50 prüfbare Abnahmekriterien** (`AC-01-...`) abgenommen — je Kernfunktion, jedes mit verifizierendem Test und, wo einschlägig, NfA-Bezug. Auszug:

Kernfunktion	Abnahmekriterium (Auszug)	NfA-Bezug	Prüfung
Erfassung (UI/API)	<code>POST /api/v1/captures</code> → 201, p95 < 200 ms (AC-08-1)	NfA-01 / NF-09	<code>Api.IntegrationTests</code> · <code>just smoke-prod</code>
Klassifikation & Routing	URL-Capture → <code>Completed</code> , <code>MatchedSkill=Wallabag</code> , <code>ExternalRef</code> gesetzt (AC-09-1)	—	<code>Skills.ContractTests</code> · <code>just test-beta</code>
KI-Fallback (Guardrail)	ungültiger API-Key → Capture erreicht <code>Classified</code> via <code>KeywordClassifier</code> ; <code>EventId 3010</code> geloggt; nie Exception (AC-10-1...3)	Zuverlässigkeit	<code>AiClassifierTests</code>
Suche & Filter	Deep-Link <code>/captures?lc=orphan</code> filtert korrekt; Listen-Abfrage p95 < 100 ms (AC-05-1)	NfA-01	<code>bUnit</code> <code>CapturesList</code> <code>PageTests</code>
Deployment	<code>docker compose up --wait</code> → exit 0, alle <code>service_healthy</code> ; <code>/health/live</code> 200 < 30 s (AC-17-1/3)	NfA-D3	<code>just smoke-prod</code>

Vollständiger Katalog (50 AC mit *Verified-by* und NfA-Verknüpfung):
[docs/spec/acceptance-criteria.md](#).

9. Architekturentscheidungen (ADR)

Volltext je ADR in `docs/adr/`. Alle neun ADRs haben den Status *Accepted* — d. h. die Entscheidung wurde getroffen und ist in der Lösung umgesetzt (im Gegensatz zu *Proposed*, *Rejected* oder *Superseded*).

Tabelle 5: Architekturentscheidungen (ADR-Übersicht)

ADR	Titel	Entscheidung (Kurz)
0001	Frontend Render Mode & Architecture	Blazor Interactive Server; UI ruft Services in-process (kein REST für UI); OIDC/Authentik; flaches <code>source/</code> -Layout; Web ist selbst ein Channel
0002	Service Architecture & Async Communication	Modularer Monolith (logischer, kein physischer Split); MassTransit-Bus; ausgehende Integrationen synchron in Consumern; kein gRPC; <code>/api/v1</code>
0003	Async Pipeline (MassTransit)	Zwei Events (<code>CaptureCreated</code> , <code>CaptureClassified</code>); Per-Consumer-Retry; <code>LifecycleFaultObserver</code> ; Kebab-Queue-Namen
0004	AI Integration — Provider-Abstraktion	MEAI <code>IChatClient</code> ; Anthropic + OpenRouter; strukturierte Ausgabe; Keyword-Fallback
0005	Persistence — EF Core + PostgreSQL	EF Core 10, Code-First-Migrations, Cursor-Pagination, interne Entities, Migrations als Init-Container
0006	Vector Search — pgvector + Embeddings	pgvector auf bestehender Postgres, HNSW-Cosine, Embedding off-request-path; OpenAI-kompatibler Provider via ENV
0007	LLM Hosting	<i>Ziel:</i> lokales Ollama als Default, Cloud als expliziter Opt-in — noch nicht umgesetzt, Cloud ist Live-Default
0008	Logging Policy	Kein PII/Capture-Body im Log; source-gen <code>LoggerMessage</code> ; Allow-List + Scrubber
0009	Telemetry & PII Policy	OTel-Span-Tag-Allow-List (<code>flowhub.*</code>), Low-Cardinality; Tracing im Abgabe-Build noch nicht aktiv

Projektbeschreibung §7 listet zusätzlich die frühen Plattform-/Strategie-Entscheidungen (PE-1...PE-7), entkoppelt von den Implementierungs-ADRs.

10. Qualitätsanforderungen

SMART-Anforderungen aus `docs/spec/nfa.md` :

Tabelle 6: Qualitätsanforderungen (SMART-NfA)

ID	Kategorie	Ziel	Messung
Nf A-01	Performance	Capture-Listen-Abfrage (Limit ≤ 50) p95 < 100 ms	OTel-Span-Dauer auf <code>ListAsync</code> ; Testcontainers mit 10k Zeilen
Nf A-02	Performance	B-Tree-Index auf jeder häufigen Filterspalte	<code>HasIndex</code> im Modell + Migration; <code>EXPLAIN</code> zeigt Index-Scans
Nf A-03	Betriebbarkeit	Code-First-Migrations, idempotentes SQL via Init-Container, kein Auto-Migrate	Migrationsdateien; <code>migrations script --idempotent</code> ; Init-Container
Nf A-04	Skalierbarkeit	Volumen-Obergrenzen (Captures $\leq 100k$, HealthSamples $\leq 10k$ /Integration, SkillRuns $\leq 500k$)	dokumentiert; Lasttest seedet 10k Zeilen
Nf A-05	Zuverlässigkeit	Npgsql-Pool + transiente Retries	Data-Source-Optionen; Integrationstests
Nf A-D1	Deployment	Image-Cold-Build < 5 min	<code>release.yml</code> -Build-Schritt ≤ 300 s
Nf A-D2	Deployment	Veröffentlichtes Image < 200 MB komprimiert	GHCR-Layer-Größen
Nf A-D3	Deployment	<code>/health/live</code> < 30 s nach Cold-Start	Compose-Healthcheck 10 s $\times$ 3

ID	Kategorie	Ziel	Messung
Nf A-O1	Beobachtbarkeit	Prometheus <code>/metrics</code> exponiert	<code>curl /metrics</code> → 200, <code>dotnet_*</code> + <code>http_*</code>
Nf A-P1	Datenschutz (Ziel)	Verarbeitung nur auf eigener Infrastruktur; LLM lokal (Ollama)	<code>OutboundCallAuditTests</code> — heute nicht erfüllt (Cloud aktiv)
Nf A-P2	Datenschutz (Ziel)	KI-klassifizierte Captures sichtbar gekennzeichnet + Provenienz	Badge-Test + Migration + API-Felder — nicht gebaut

11. Risiken und technische Schulden

Tabelle 7: Risiken und technische Schulden

Punkt	Art	Status / Mitigation
EF-Outbox nicht verdrahtet	Tech. Schuld	Crash zwischen Persist und Publish kann einen Capture in <code>Raw</code> zurücklassen; Mitigation: manueller Retry-Endpoint + Dashboard-Sichtbarkeit (ADR 0003)
OTLP-Tracing	Erledigt	Aktiv (ADR 0009): <code>WithTracing(...)</code> + <code>TagAllowListProcessor</code> + <code>FlowHubActivityTags</code> -Helper; Console-Export always-on, OTLP über <code>Otlp__Endpoint</code> ; Audit-Test <code>TagAllowListProcessorTests</code> (12 Fälle) verriegelt die PII-Policy. KI-Metriken (Confidence-Score-Histogramm etc.) bleiben offen.
NfA-P1 / NfA-P2 offen	Ziel offen	Cloud-LLM + Cloud-Embeddings sind Live-Default; kein lokaler Ollama-Adapter, keine KI-Badges und keine Provenienz-Spalten — also keine Herkunftsfelder wie <code>ClassificationSource</code> (KI / Heuristik / Manuell), <code>ClassifiedAt</code> , <code>ConfidenceScore</code> , die festhalten, <i>wie</i> ein Capture klassifiziert wurde

Punkt	Art	Status / Mitigation
Compliance-Audit-Tests geplant	Tech. Schul d	<code>SerilogPiiAuditTests</code> , <code>TracingPiiAuditTests</code> , <code>OutboundCallAuditTests</code> als Block-5/geplant markiert
Semantische Suche auf Demo zurückge rollt	Bewusste Einschränkung	Self-hosted Embedder getestet, dann entfernt (schwache Trennschärfe auf kleinem Datensatz); <code>/search</code> → 503; Pipeline + Tests bleiben als Deliverable (ADR 0006 Amendment)
Idempotenz-Receiver fehlt	Tech. Schul d	RabbitMQ-At-least-once-Redelivery nicht abgesichert
Scope Creep (zu viele Skills)	Projektrisiko	Schlanke MVP-Liste, Future klar abgegrenzt
Ollama zu langsam (kein GPU)	Projektrisiko	Cloud-Fallback + Keyword-Baseline
Zeitdruck (Abgabe Juli)	Projektrisiko	MVP bewusst schlank, Future-Features dokumentiert

12. Glossar

Begriff	Bedeutung
Capture	Eingehender Informationsschnipsel (URL, Text, Datei); Aggregat-Root mit Lifecycle-Stage, Source, MatchedSkill, Tags, Title, ExternalRef, Embedding

Begriff	Bedeutung
Skill	Kategorie/Handler für einen Capture-Typ; routet zu genau einem Ziel-Dienst. Ist-Mechanismus: <code>MatchedSkill</code> -String auf eine <code>ISkillIntegration.Name</code> abgebildet
Channel	Eingangs-Quelle für Captures (Web Quick-Capture, REST-API; Telegram geplant). Die Web-UI ist selbst ein Channel (ADR 0001)
Integration	Ausgehender Adapter zu einem Ziel-Dienst (<code>ISkillIntegration</code>); verdrahtet: Wallabag, Vikunja
Lifecycle- Stages	<code>Raw</code> → <code>Classified</code> → <code>Routed</code> → <code>Completed</code> ; Fehler-Terminale <code>Orphan</code> und <code>Unhandled</code> (beide retry-bar)
MEAI	Microsoft.Extensions.AI — Provider-Abstraktion für LLMs in .NET
EF Core	Entity Framework Core — .NET-ORM
Blazor SSR	Server-seitiges Rendering mit Blazor
Homelab	Selbst betriebene Server-Infrastruktur (Proxmox)

Abkürzungen

Kürzel	Bedeutung
MEAI	Microsoft.Extensions.AI — Provider-Abstraktion für LLMs in .NET
ORM	Object-Relational Mapper (hier EF Core) — bildet Objekte auf DB-Tabellen ab
DI	Dependency Injection — Abhängigkeiten werden injiziert statt selbst erzeugt
SSR / CSR	Server-Side / Client-Side Rendering
OIDC / SSO	OpenID Connect / Single Sign-On — Authentifizierung über einen zentralen Identity-Provider (Authentik)

Kürzel	Bedeutung
pgvector	PostgreSQL-Erweiterung für Vektor-Spalten + Ähnlichkeitssuche
HNSW	Hierarchical Navigable Small World — Approximate-Nearest-Neighbour-Index für Vektorsuche
OTLP	OpenTelemetry Protocol — Wire-Format zum Senden von Traces/Metriken an einen Collector
GHCR	GitHub Container Registry — hostet die veröffentlichten Docker-Images
RFC 9457	Standard für maschinenlesbare HTTP-Fehler („Problem Details“)
DTO	Data Transfer Object — einfaches Datenobjekt für die Übertragung über eine Grenze

Abbildungsverzeichnis

- **Abbildung 1:** System-Kontext (C4 Level 1) — Kap. 3.2
- **Abbildung 2:** Ist-Architektur — Bausteinsicht Ebene 1 (modularer Monolith) — Kap. 5.1
- **Abbildung 3:** Datenmodell (Entity-Relationship) — Kap. 5.6
- **Abbildung 4:** Schnittstellen-/Interaktionssicht — Vertrags-Kontrakte (REST, Ports, Events) — Kap. 5.7
- **Abbildung 5:** Capture-Lebenszyklus (Zustandsdiagramm) — Kap. 6.1
- **Abbildung 6:** Hot-Path — Submit bis Skill-Write (Sequenz) — Kap. 6.2
- **Abbildung 7:** Enrichment — Happy Path (Sequenz) — Kap. 6.3
- **Abbildung 8:** Enrichment — Fallback auf KeywordClassifier (Sequenz) — Kap. 6.4
- **Abbildung 9:** Skill-Routing — Erfolg (Sequenz) — Kap. 6.5
- **Abbildung 10:** Skill-Routing — Retry-Erschöpfung & Fault-Observer (Sequenz) — Kap. 6.6

Tabellenverzeichnis

- **Tabelle 1:** Qualitätsziele (Auszug) — Kap. 1.2
- **Tabelle 2:** Stakeholder — Kap. 1.3
- **Tabelle 3:** Anwendungsfälle (UC-Überblick) — Kap. 1.4
- **Tabelle 4:** Schnittstellen-Verträge (Detail zu Abbildung 4) — Kap. 5.7
- **Tabelle 5:** Architekturentscheidungen (ADR-Übersicht) — Kap. 9
- **Tabelle 6:** Qualitätsanforderungen (SMART-NfA) — Kap. 10
- **Tabelle 7:** Risiken und technische Schulden — Kap. 11

Literaturverzeichnis

- arc42 — Template für Architekturdokumentation, v8. <https://arc42.org>
- Simon Brown — *The C4 model for visualising software architecture*. <https://c4model.com>
- *The Twelve-Factor App*. <https://12factor.net>
- IETF RFC 9457 — *Problem Details for HTTP APIs*. <https://www.rfc-editor.org/rfc/rfc9457>
- Microsoft — *Microsoft.Extensions.AI (MEAI) Dokumentation*. <https://learn.microsoft.com/dotnet/ai/>
- Microsoft — *Entity Framework Core Dokumentation*. <https://learn.microsoft.com/ef/core/>
- MassTransit — Dokumentation. <https://masstransit.io>
- pgvector — *Open-source vector similarity search for Postgres (HNSW-Index)*. <https://github.com/pgvector/pgvector>
- Malkov & Yashunin (2018) — *Efficient and robust approximate nearest neighbor search using HNSW graphs*. IEEE TPAMI.

Anhang

Der vollständige Quellcode, die ADR-Volltexte (0001-0009), Spezifikations- und Design-Dokumente sowie die Test-Suite liegen im Repository und sind aus der Einreichungs-Seite (`FlowHub_Uebersicht`) verlinkt:

<https://github.com/freaxnx01/FlowHub-CAS-AISE>. Das Hilfsmittelverzeichnis und die Selbständigkeitserklärung sind dem separaten Dokument

`Eigenständigkeitserklärung` beigelegt.

Arc42 v2.0 (as built), Juni 2026. Erstellt mit Unterstützung von Claude (Anthropic) gemäss den FFHS-Richtlinien für KI-Einsatz in Projektarbeiten.